

| EM方案

| 1. 现在已完成的工作

| 1.1 已完成pipeline

- 数据预处理：把离线交易明细读入为结构化表（含去空、类型转换、基础缺失处理、必要的抽样/切片）。
- 特征工程：构造数值/类别/时间特征；对类别型特征训练并加载 embedding，使其可被下游模型稳定使用。
- 建图与张量化：基于 `debit_account_masked` → `bene_account_masked` 生成账户-账户交易图（多边保留），并把节点/边/时间等信息转为图学习可用的特征张量。
- 模型训练：
 - 表格侧：训练 IF/LOF/AE 及 ensemble，得到交易级异常分数；
 - 图侧：训练 GraphMAE，自监督学习账户表征并产出账户级异常信号。
- 融合与落盘：支持门控融合等策略产出融合后的风险分数，并落盘输出文件；同时生成无标签诊断报告与可视化图表。

| 1.2 两路无监督信号

- 表格侧（交易级）：IsolationForest、LOF、AutoEncoder 及其 ensemble，输出交易异常分数。
- 图侧（账户级）：GraphMAE 自监督图表征学习，输出账户/节点异常分数。

| 2. Motivation

| 2.1 将分数排序转换为“统一概率”

目标是形成交易级统一概率输出：

- 可配置阈值（对接容量/策略）；
- 可解释分解项（表格贡献、图贡献、门控权重）

| 2.2 两个模型的互补

1. 现有系统天然具备互补性：
 - 表格侧擅长捕捉字段异常与局部模式（交易级）
 - 图侧擅长捕捉结构/关系异常（账户级）
2. 当前的表格侧模型不是可迭代的

| 2.3 EM 的合适性：用“后验软标签”作为两侧对齐语言

EM-style 的核心价值是：

- 把“异常/欺诈”作为潜变量，用 **E-step 推断后验**（软标签/概率）来统一语义；
- 用 **M-step 在软标签下更新模型**，让表格与图互相学习；
- 采用 **generalized EM** 可允许每轮只要“改善目标”即可，工程上更可行。

2.4 无标签场景必须“可控”：EM 允许把约束写进 E-step

无标签下最大风险是反馈回路与退化解。EM 方案的优势之一在于：

- 可把先验异常率、语义锚点、置信度门控等约束写成“约束型后验推断”，让迭代可控、可诊断、可停机。

3. EM-style Plan：算法流程详解

3.1 核心对象与符号

符号	含义	取值
$e = (u \rightarrow v)$	一笔交易，从付款账户 u 到收款账户 v	—
v	一个账户（图中的节点）	—
z_e	潜变量	0（正常）或 1（异常）
q_e	对 z_e 的最佳猜测——统一风险概率 <code>p_final</code>	0–1
r_v	图侧给账户 v 打账户风险	0–1
$\hat{p}_e^T$	表格侧给交易 e 打的交易风险	0–1
α_e	门控权重	0–1
π	先验异常率	默认约 3×10^{-4}
b	偏置项	实数

3.2 Generalized EM

经典 EM 的目标是最大化含潜变量的对数似然：

$$\log p_{\theta}(X) = \log \sum_Z p_{\theta}(X, Z)$$

含义：观察到了数据 X （所有交易和账户特征），但不知道哪些交易是欺诈（潜变量 Z ）。EM 的目标是找到一组模型参数 θ ，使得“在所有可能的欺诈/正常划分下，数据出现的总概率”最大。

并通过两步交替：

- **E-step**：推断潜变量后验（或其近似）

$$\overset{\text{EM方案}}{q(Z)} \leftarrow p_{\theta^{old}}(Z | X)$$

含义：在当前模型参数不变的前提下，重新估计"每笔交易是欺诈的概率"——也就是更新我们对每笔交易的"猜测"。

- **M-step**：在后验固定时更新参数

$$\theta^{\text{new}} \leftarrow \arg \max_{\theta} \mathbb{E}_{q(Z)} [\log p_{\theta}(X, Z)]$$

含义：把上一步的猜测当成"软标签"（不是非黑即白的 0/1，而是 0–1 之间的概率），用它去重新训练模型，让模型变得更准。

对本任务而言，更贴合的是 Generalized EM（宽松版 EM）：

- 表格侧在迭代中使用可学习模型（如 AE + 风险头 或 MLP），并在第 0 轮先训练 AE（以重构误差 + 可能的正则作为自监督目标）得到初始异常信号/概率校准锚点；在这种“先自监督预训练、再交替互学”的流程下，第 0 轮往往不具备严格的极大似然 argmax 形式，因此采用 generalized EM 更贴合工程现实；
- 图侧同时包含自监督目标（GraphMAE 重构）与"风险头"目标，严格 M-step 也不现实；

含义：Generalized EM 只要求每一步都比上一步"更好一点"就行。

因此每轮只要做到"朝着更一致、更可控的后验语义推进"，就满足 Generalized EM 的工程使用方式。

3.3 算法输入与初始化

1. 表格侧初始化：

- 先训练表格侧 AE（可加稀疏/去噪等正则），以重构误差得到交易级异常分数 s_e^{AE} ；

AE（自编码器）的原理是"学会把正常交易压缩再还原"。如果一笔交易的特征很难被还原（重构误差大），说明它跟大部分正常交易长得不一样，更可能是异常的。

- 将 s_e^{AE} 单调映射并校准为初始概率形态 $\hat{p}_e^{T,0}$ （例如在分位数/秩空间做映射，再用先验异常率 π 做整体校准）。

：AE 输出的重构误差只是一个"分数"（可能从 0 到 100 不等），不是概率。我们需要把它转换成 0–1 之间的概率，并且让全局的平均异常概率大约等于先验 π （例如万分之三），这样后续迭代才有稳定的起点。

2. 图侧初始化：

- 运行图侧自监督训练，得到账户级异常信号 s_v^G ；
- 将 s_v^G 映射成账户风险 r_v^0 。

初始化完成后的状态：表格侧有了每笔交易的初始风险概率 $\hat{p}_e^{T,0}$ ，图侧有了每个账户的初始风险概率 r_v^0 。两套初始判断各自独立、视角互补，接下来就可以进入交替互学。

3.4 E-step（表格侧阶段）：固定图侧，更新表格侧（Graph $\rightarrow$ Tabular）

- **E-step**：固定图侧模块，用图侧输出构造交易级后验/伪标签 q_e ，再用 q_e 更新表格侧可学习模型；
- **M-step**：固定表格侧模块，用表格侧输出回传给账户级软目标 $\tilde{r}_v$ ，再用 $\tilde{r}_v$ 更新图侧风险头（同时保留 GraphMAE 自监督目标作稳定器）。

3.4.1 账户 $\rightarrow$ 交易：把账户风险映射为交易贡献 $p_e^{G \rightarrow E}$

对于交易 $e = (u \rightarrow v)$ ，图侧对交易的风险贡献可用端点风险组合而来，例如 Noisy-OR：

$$p_e^{G \rightarrow E} = 1 - (1 - r_u)(1 - r_v)$$

3.4.2 置信度门控：计算 α_e （避免碎片化图噪声传播）

α_e 表示“这笔交易更信图还是更信表格”。它通常依赖端点账户的度数/活跃度：

- 冷启动/低度账户：图信息不可靠， α_e 应更小（比如 0.1），意味着 90% 权重给表格侧；
- 高度账户：结构信息更丰富， α_e 可以更大（比如 0.5–0.7），让图侧意见有更大影响力。

3.4.3 logit 空间融合：得到未约束的后验 q_e

在 logit 空间融合：

$$\text{logit}(q_e) = \alpha_e \cdot \text{logit}(p_e^{G \rightarrow E}) + (1 - \alpha_e) \cdot \text{logit}(\hat{p}_e^T) + b$$

3.4.4 先验异常率约束：用 b 让 $\text{mean}(q_e) \approx \pi$

全局约束：

$$\frac{1}{N} \sum_e q_e \approx \pi$$

3.4.5 E-step 的核心动作：用 q_e 更新表格侧可学习模型

这一步才是 E-step 最重要的事：前面 3.4.1–3.4.4 都是在“算出统一后验 q_e ”，而这一步是“用 q_e 去教表格侧模型”。这就像老师（图侧+融合后验）出了一张考卷（ q_e ），学生（表格侧模型）根据考卷上的答案来学习，让自己的判断越来越接近统一标准。

构造好 q_e 后，E-step 最关键的一步是 把图侧结构信息蒸馏进表格侧——用 q_e 作为交易级软目标训练表格侧模型，使表格侧输出 $\hat{p}_e^T$ 逐轮逼近统一后验：

E-step 结束后，表格侧输出 $\hat{p}_e^T$ 已经吸收了图侧结构信号，下一轮的 q_e 融合时两侧更一致。

3.5 M-step 前序：交易 $\rightarrow$ 账户聚合，从 q_e 构造账户软目标 $\tilde{r}_v$

E-step 产出的 q_e 是交易级的，但图侧模型工作在账户级

进入 M-step 之前，需要把交易级后验 **反向聚合** 到账户级，为图侧训练提供监督信号：

- 一般形式： $\tilde{r}_v = \text{Agg}(\{q_e : e \in \mathcal{E}(v)\})$

3.6 M-step（图侧阶段）：固定表格侧，更新图侧（Tabular $\rightarrow$ Graph）

在 M-step 中，表格侧参数固定不动、图侧被更新。目标是把表格侧的交易语义通过 $q_e \rightarrow \tilde{r}_v$ 蒸馏进图侧风险输出，使其逐轮更一致：

- **表格侧（固定）**：提供交易级概率 $\hat{p}_e^T$ （以及可选交易表征），用于构造/稳定 q_e 并回传到账户软目标 $\tilde{r}_v$ 。
- **图侧（更新）**：
 - **风险头训练**：用 $\tilde{r}_v$ 作为节点级 soft target，训练一个轻量风险头（接在 GraphMAE encoder 输出之后），使账户风险 r_v 贴近交易后验语义；
 - **自监督稳定器**：GraphMAE 的 masked-feature 重构损失继续保留，确保图编码器不会因风险头的梯度信号而丢失结构表征能力；
 - **联合损失**： $\mathcal{L}_{\text{graph}} = \lambda_{\text{recon}} \mathcal{L}_{\text{MAE}} + \lambda_{\text{risk}} \mathcal{L}_{\text{risk}}(\tilde{r}_v, r_v)$ ，其中 λ 控制两项的平衡。

M-step 结束后的状态：图侧账户风险 r_v 已经吸收了表格侧交易语义；下一轮 E-step 再把更新后的 r_v 映射回交易级，形成“双向蒸馏”闭环。